

HandTracking

Pessina Leonardo, Valsecchi Christian

a.s. 2025/2026

Indice:

- 1 Introduzione**
 - 1.1 Origini**
 - 1.2 Perché l'HandTracking?**
- 2 Teoria**
 - 2.1 Object Detection e Regressione**
 - 2.2 Stima bayesiana ricorsiva**
 - 2.3 Classificazione a massimo margine**
 - 2.4 Ensemble di alberi decisionali**
 - 2.5 Normalizzazione dei dati**
- 3 Possibili implementazioni**
- 4 La nostra proiezione**

1 Introduzione

Il presente elaborato è il frutto di ore di ricerca impiegate in queste settimane, oltre che del duro lavoro svolto da brillanti menti nel corso di questo secolo. Tale tecnologia ha compiuto passi da gigante da quando fu per la prima volta sviluppata dall'artista americano [Myron Krueger](#) nel 1969. Affascinante è come un artista fu pioniere di una tecnologia così all'avanguardia quale è la realtà virtuale (VR) o la realtà aumentata (AR). Quest'ultima, difatti, è ciò che Krueger sviluppò al suo tempo e per la quale conìò, nel 1973, il termine "*Artificial Reality*". La definizione che ci offre un'intervista rilasciata da Jeremy Turner datata al 23 gennaio 2002 è sufficientemente chiara e concisa: una "realtà artificiale" è un ambiente reattivo ai movimenti e ai gesti di chi la sta visualizzando mediante piani sensoriali, *tavolette grafiche* e videocamere. Il sistema permetteva un'interazione diretta tra i partecipanti e le proiezioni video reciproche, all'interno di un ecosistema digitale condiviso e multi-utente.



Figure 1: Myron Krueger (sinistra) e Dan Sandin, a *Ars Electronica '99*

1.1 Origini

Le radici di questa tecnologia affondano nel 1969, quando Krueger e alcuni colleghi realizzarono *Glowflow*, un'installazione interattiva presso la University of Wisconsin: tubi fluorescenti reagivano alla presenza dei visitatori, costituendo il primo esperimento di ambiente computazionale **responsivo al corpo umano**. Fu tuttavia con *Metaplay* (1970) che il gesto cominciò ad assumere un ruolo centrale: il sistema proiettava in tempo reale la silhouette del visitatore su uno schermo condiviso, fondendo presenza fisica e rappresentazione digitale. Il culmine di questa ricerca giunse nel 1974 con *Videoplace*, il capolavoro di Krueger: un sistema di telecamere catturava la silhouette dell'utente e la inseriva in un mondo grafico, consentendo a due persone situate in stanze separate di

interagire attraverso le proprie immagini proiettate. Per la prima volta, la mano diventava **interfaccia consapevole** senza guanti e senza dispositivi interposti tra corpo e sistema.




Figure 2: Risultati artistici ottenuti da Krueger

Questo principio, che Krueger stesso definiva come l'ideale di un *corpo senza protesi*, avrebbe guidato decenni di ricerca successiva. Nel 1983 egli pubblicò il testo fondativo della disciplina, *Artificial Reality*, in cui teorizzava ambienti computazionali capaci di riconoscere gesti, posture e movimenti corporei come forma primaria di interazione uomo-macchina. La comunità scientifica raccolse questa eredità: nel 1987 [Jaron Lanier](#) e [VPL Research](#) commercializzarono il primo guanto per realtà virtuale – il *DataGlove* –, in cui sensori in fibra ottica rilevavano la flessione di ogni dito, rendendo l'hand tracking un prodotto fruibile, sebbene ancora dipendente da hardware indossato.

Il passo decisivo verso la visione di Krueger – la mano nuda come unico strumento – maturò nei laboratori accademici degli anni Novanta, dove algoritmi di visione artificiale cominciarono a riconoscere la mano da semplici telecamere, senza alcun marker fisico. Fu solo con l'introduzione del sensore *Kinect* di Microsoft (2010) che questa tecnologia raggiunse il mercato di massa: il corpo intero, mani incluse, diventava telecomando, quarant'anni dopo i primi esperimenti di Krueger. L'approdo più recente di questa traiettoria è rappresentato dall'integrazione del riconoscimento gestuale nativo nei visori per realtà virtuale consumer, dove reti neurali convoluzionali tracciano in tempo reale ventisei punti articolari della mano a sessanta fotogrammi al secondo, senza alcun dispositivo aggiuntivo. Ciò che Krueger immaginava come utopia interattiva è oggi funzione di serie: il tutto nato da una **mente artistica**.

1.2 Perché l’handtracking

Dopo aver trattato in breve l’idea cardine che fu lanciata dai pionieri della realtà aumentata, è doveroso esplicitare le motivazioni che ci hanno spinti a trattare questo argomento piuttosto che altri. Definire la nostra visione ”lungimirante” sarebbe un eufemismo: riteniamo che questa tecnologia possa portare enormi benefici e comodità nella vita di ognuno di noi. L’handtracking o, più in generale, il riconoscimento di forme, figure e oggetti mediante l’impiego di un ”occhio” artificiale – banalmente una foto/videocamera – può avere miriadi di impieghi in numerosi campi lavorativi e ludici ma anche nella vita quotidiana.

L’**elettronica di consumo** (”indossabile”) ha raggiunto, nel 2025, secondo [MarketsAndMarkets](#), una quota di mercato superiore al 50% e, secondo il [reportage di mercato](#), un valore compreso tra 1,2 e 3,1 miliardi di dollari, oltre ad aver trovato terreno fertile nel settore medico (formazione chirurgica, [telemedicina](#)), automobilistico ([HMI In-Car](#)) e industriale (manutenzione e robotica). Si prevede, inoltre, una crescita esplosiva che sfiorerà i 10 miliardi di dollari entro il 2033.

L’ambito videoludico è quello dominante con lo sviluppo di Realtà Virtuale e Aumentata (VR/AR). Dispositivi come il *Meta Quest* e l’*Apple Vision Pro* utilizzano l’hand tracking come interfaccia nativa per navigare nei menu, interagire con oggetti virtuali e giocare senza controller. Il settore automobilistico resta uno dei campi a più rapida crescita. Entro il 2026, si stima che il 30% dei nuovi veicoli integrerà controlli gestuali per permettere ai conducenti di regolare volume, temperatura o navigazione senza staccare gli occhi dalla strada. Viene impiegato massicciamente per la simulazione chirurgica e la riabilitazione, consentendo ai medici di esercitarsi in ambienti virtuali con una precisione manuale realistica.

È, dunque, evidente come le varie tecnologie indossabili si stiano affermando nel mercato con enorme successo e vasto margine di crescita in popolarità. Proprio per questo motivo abbiamo deciso di presentare in maniera, più o meno, chiara, seppur con parecchi tecnicismi, la realtà dell’handtracking e dell’*object detection*, approfondendone la teoria che ne sta alla base e trattando i benefici che può portare all’Uomo, pur sempre adottando una visione critica che possa aiutare chi leggerà questo trattato a individuare quelli che potrebbero essere gli aspetti negativi che potrebbe assumere.

2 Teoria

2.1 Object Detection e Regressione

La scelta di indagare le potenzialità dell'handtracking non risponde solo a un interesse verso le tecnologie emergenti, ma anche dalla volontà di esplorare nuovi orizzonti di accessibilità digitale. Per trasporre questa riflessione dal piano dell'intuizione a quello dell'analisi rigorosa, è fondamentale analizzare i pilastri teorici che sostengono la tecnologia, partendo dai modelli di elaborazione dell'immagine.

2.1.1 Definizione del problema

Rilevamento di oggetti e regressione nell'algoritmo YOLO

L'object detection costituisce un problema composito che integra due sotto-task distinte: la **classificazione** degli oggetti presenti in un'immagine, volta ad assegnare a ciascuno di essi una categoria semantica, e la **localizzazione**, finalizzata a determinarne la posizione spaziale all'interno del fotogramma mediante l'impiego di *bounding box* rettangolari. La difficoltà principale risiede nella necessità di risolvere entrambi i problemi simultaneamente, su un numero variabile e a priori sconosciuto di oggetti per immagine.

I sistemi tradizionali affrontano questo problema in modo sequenziale: una prima fase identifica le **regioni candidate** (o *region proposals*), una seconda le classifica. YOLO adotta invece un approccio

radicalmente diverso, riformulando l'intera procedura come un singolo problema di regressione risolto in un passaggio unico.

2.1.2 Regressione diretta delle bounding boxes

Il contributo fondamentale di YOLO consiste nel trattare il rilevamento di oggetti come un problema di regressione spaziale. Anziché classificare regioni proposte da un algoritmo esterno, la rete apprende direttamente una funzione che mappa i pixel dell'immagine di ingresso verso un insieme di predizioni strutturate.

A tal fine, l'immagine viene suddivisa in una griglia di $S \times S$ celle. Per ciascuna cella, la rete predice simultaneamente un numero B di bounding box. Ogni bounding box è parametrizzata da un vettore a cinque componenti:

$$b_j := (x_j, y_j, w_j, h_j, \text{conf}_{b_j})$$

dove (x_j, y_j) rappresentano le coordinate del centro della bounding box espresse in forma relativa rispetto ai bordi della cella; (w_j, h_j) indicano rispettivamente la larghezza e l'altezza normalizzate rispetto alle dimensioni dell'intera immagine; conf_{b_j} è il *box confidence score*, definito come:

$$\text{conf}_{b_j} := P(\text{Object}) \cdot \text{IoU}(b_j, b_c)$$

Il termine $P(\text{Object})$ esprime la probabilità che nella bounding

box sia contenuto un oggetto, mentre $\text{IoU}(b_j, b_c)$ quantifica la qualità della localizzazione attraverso il rapporto tra l'area di intersezione e l'area di unione tra la bounding box predetta b_j e quella di riferimento b_c (*ground truth box*). Il *confidence score* risultante codifica quindi sia l'**accuratezza** della classificazione binaria oggetto/sfondo, sia la precisione geometrica della predizione.

2.1.3 Classificazione e class confidence score

In parallelo alla regressione delle bounding box, ciascuna cella della griglia stima la distribuzione di probabilità condizionata $P(C_i | \text{Object})$ su C classi. Il *class confidence score* per la classe C_i associata alla bounding box b_j è definito come:

$$\text{conf}_{C_i, b_j} = P(C_i) \cdot \text{IoU}(b_j, b_c)$$

Tale formulazione, ottenuta sviluppando il prodotto tra il *box confidence score* e la probabilità condizionata per applicazione del teorema della probabilità totale, integra in un unico scalare due informazioni distinte: la probabilità **a priori** che l'oggetto appartenga alla classe C_i , e la **precisione geometrica** della bounding box associata. La classe assegnata a ciascuna bounding box corrisponde a quella con class confidence score massimo.

2.1.4 Struttura dell'output e formulazione regressiva

Il tensore di output della rete ha forma:

$$y = (S, S, B \times 5 + C)$$

che, per la configurazione standard con $S = 7$, $B = 2$ e $C = 20$ classi, produce $7 \times 7 \times 30 = 1470$ valori. L'intero processo di predizione è dunque riconducibile a una **regressione multivariata**, in cui la rete apprende i parametri di una funzione non lineare – implementata attraverso 24 livelli convoluzionali seguiti da 2 livelli *fully connected* – che trasforma l'immagine di ingresso in tale tensore strutturato. L'ultimo livello impiega una funzione di attivazione lineare, coerentemente con la natura regressiva dell'operazione; i livelli intermedi adottano invece la *Leaky ReLU*.

2.1.5 Funzione di costo per la regressione

La funzione di costo adottata è la *sum of squared errors* (SSE), articolata in tre contributi che penalizzano separatamente i diversi tipi di errore di regressione.

La **localization loss** misura l'errore geometrico delle *bounding boxes* responsabili, ovvero quelle con IoU massimo rispetto alla *ground truth*:

$$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} [(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2] + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right]$$

Il coefficiente $\lambda_{\text{coord}} = 5$ attribuisce maggiore peso agli errori

di localizzazione rispetto agli altri termini. L'impiego delle radici quadrate di larghezza e altezza consente di applicare una penalizzazione proporzionalmente maggiore agli errori geometrici su *bounding boxes* di piccole dimensioni, evitando che errori assoluti identici su oggetti di scala diversa abbiano lo stesso impatto sulla perdita (loss).

La **confidence loss** penalizza l'errore nella stima del *box confidence score*, distinguendo due casi. Per le *bounding boxes* responsabili di un oggetto:

$$\sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} (C_{ij} - \hat{C}_{ij})^2$$

Per le *bounding boxes* prive di oggetto, il contributo è pesato da $\lambda_{\text{noobj}} = 0.5$, valore inferiore all'unità al fine di ridurre l'influenza delle celle di sfondo — largamente maggioritarie — sull'aggiornamento dei pesi:

$$\lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{noobj}} (C_{ij} - \hat{C}_{ij})^2$$

La **classification loss** quantifica l'errore nella stima delle probabilità di classe per le celle contenenti un oggetto:

$$\sum_{i=0}^{S^2} \mathbb{K}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2$$

2.1.6 Post-elaborazione: non-maximum suppression

A seguito dell'inferenza, il numero di *bounding box* generate ($S^2 \times B$) risulta elevato e largamente ridondante. La procedura di *non-maximum suppression* seleziona, per ciascuna classe, la *bounding box* con *class confidence score* massimo ed elimina iterativamente tutte quelle con IoU superiore a una soglia prefissata rispetto alla predizione selezionata. Il risultato è un insieme minimale di *bounding box*, ciascuna rappresentativa di un singolo oggetto rilevato.

2.1.7 Sintesi

YOLO riconduce il problema dell'*object detection* a una regressione diretta eseguita in un singolo passaggio di rete. La formulazione unificata della *loss function* — che penalizza congiuntamente errori di localizzazione, di stima della confidenza e di classificazione — consente di addestrare la rete in modo end-to-end, senza stadi separati. Questo approccio determina una riduzione significativa della latenza di inferenza rispetto ai *two-stage detector*, al costo di una minore precisione nella localizzazione di oggetti di piccole dimensioni, limitazione parzialmente mitigata nelle versioni successive dell'algoritmo attraverso l'introduzione delle *anchor box* e di architetture *backbone* più profonde.

2.2 Stima bayesiana ricorsiva

2.2.1 Fondamento teorico

L'inferenza bayesiana si fonda sul **teorema di Bayes**, che descrive come aggiornare la conoscenza su un parametro di interesse θ alla luce dei dati osservati. La formulazione è la seguente:

$$\pi(\theta | y) = \frac{\pi(\theta) \cdot L(y | \theta)}{\int_{\Theta} \pi(\theta) \cdot L(y | \theta) d\theta}$$

dove: - $\pi(\theta)$ è la distribuzione a priori, che codifica le conoscenze disponibili su prima di osservare i dati; - $(y|\theta)$ è la funzione di verosimiglianza, che rappresenta l'informazione portata dai dati osservati; - $\pi(\theta|y)$ è la distribuzione a posteriori, ovvero il risultato aggiornato del processo inferenziale.

2.2.2 La struttura ricorsiva

La proprietà ricorsiva dell'inferenza bayesiana emerge in modo naturale dalla struttura del teorema stesso. Il principio è il seguente: la distribuzione a posteriori ottenuta in un'analisi può fungere da distribuzione a priori per una successiva analisi, condotta su un nuovo insieme di dati.

Formalmente, si supponga di disporre inizialmente di (y_1) e di osservare un primo campione y_1 . La distribuzione a posteriori risultante è:

$$\pi(\theta | y_1) \propto \pi(\theta) \cdot L(y_1 | \theta)$$

All'arrivo di un secondo campione y_2 , questa distribuzione a posteriori viene impiegata come nuova

distribuzione a priori, producendo:

$$\pi(\theta | y_1, y_2) \propto \pi(\theta | y_1) \cdot L(y_2 | \theta)$$

Sostituendo la prima espressione nella seconda si ottiene:

$$\pi(\theta | y_1, y_2) \propto \pi(\theta) \cdot L(y_1 | \theta) \cdot L(y_2 | \theta)$$

che coincide esattamente con la distribuzione a posteriori che si otterrebbe analizzando congiuntamente y_1 e y_2 a partire dalla stessa a priori iniziale. Il risultato finale è dunque **indipendente dall'ordine con cui i dati vengono incorporati**, purché le osservazioni siano condizionatamente indipendenti dati i parametri.

2.2.3 Implicazioni pratiche

La logica ricorsiva conferisce all'inferenza bayesiana alcune proprietà operative rilevanti, che la tesi di Vignotto richiama esplicitamente. In primo luogo, il modello bayesiano si presta ad essere aggiornato in modo **sequenziale** all'arrivo di nuovi dati, senza dover ricominciare l'analisi dall'inizio. In secondo luogo, tale struttura risulta coerente con l'approccio *Divide et Impera*: quando i dati vengono suddivisi in S sottoinsiemi disgiunti, la distribuzione a posteriori globale può essere riscritta come prodotto delle distribuzioni a posteriori parziali, secondo la relazione:

$$\pi(\theta | y) \propto \prod_{s=1}^S L(y_s | \theta) \cdot \pi(\theta)^{1/S}$$

Questa scomposizione è formalmente analoga alla logica ricorsiva: ciascun sottoinsieme contribuisce sequenzialmente – o, nel caso parallelo, simultaneamente – all’aggiornamento dell’informazione su θ .

2.2.4 Nota computazionale

La principale difficoltà nell’applicazione pratica della logica bayesiana ricorsiva risiede nel calcolo della costante di normalizzazione al de-

nominatore del teorema di Bayes, che nella maggior parte dei modelli non è analitica. Come osservato nel testo, ciò ha storicamente limitato l’impiego dell’inferenza bayesiana ai soli modelli a famiglie coniugate. Lo sviluppo degli algoritmi MCMC – in particolare il Metropolis-Hastings – ha rimosso questo vincolo, rendendo possibile approssimare la distribuzione a posteriori per qualsiasi specificazione di $\pi(\theta)$ e $L(y|\theta)$, anche in presenza di grandi volumi di dati.

2.3 Classificazione a massimo margine

2.3.1 Support Vector Machines

Il documento, redatto da **Nicola Torelli** (Università di Trieste, 2023), introduce le *Support Vector Machines* (SVM) come metodi di classificazione di natura geometrica, distinti dagli approcci statistici probabilistici. L'obiettivo fondamentale è individuare un iperpiano nello spazio delle variabili predittive che separi ottimalmente due classi. La trattazione si articola in quattro nuclei concettuali principali.

2.3.2 Classificatore con Massimo Margine

Nel caso in cui le classi siano **perfettamente separabili linearmente**, si definisce un iperpiano di separazione come il luogo dei punti per cui:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p = 0$$

Poiché esistono infiniti iperpiani separatori, il criterio di selezione ottimale consiste nel massimizzare il **margine**, definito come la minima distanza tra le osservazioni e l'iperpiano. Il problema si formula come ottimizzazione vincolata: si massimizza $M > 0$ soggetto al vincolo di normalizzazione $\sum_j \beta_j^2 = 1$ e alla condizione che ogni osservazione soddisfi:

$$y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M \quad \forall i$$

Le osservazioni che giacciono esattamente sul margine sono denominate **vettori di supporto**

(*support vectors*): sono i soli punti che determinano la posizione dell'iperpiano, rendendolo indipendente dal resto dei dati.

Limite critico. L'approccio presuppone la separabilità perfetta, condizione raramente verificata in pratica. Inoltre, anche quando tale separabilità esiste, l'aggiunta di un singolo punto può modificare drasticamente l'iperpiano, rivelando una forte instabilità del metodo.

2.3.3 Classificatore con Vettori di Supporto (Soft Margin)

Per gestire i casi di non separabilità o di separazione instabile, si introduce il concetto di **margine morbido** (*soft margin*): si ammette che alcune osservazioni possano trovarsi sul lato errato del margine o persino dell'iperpiano, introducendo variabili di scarto $\varepsilon_i \geq 0$. Il problema di ottimizzazione diviene:

$$\text{massimizzare } M \quad \text{con} \quad y_i(\beta_0 + \dots + \beta_p x_{ip}) \geq M(1 - \varepsilon_i), \quad \sum_i \varepsilon_i \leq C$$

Il parametro $C > 0$ regola il **trade-off distorsione-varianza**: valori elevati di C aumentano la tolleranza alle violazioni del margine (margine più ampio, maggiore bias, minore varianza); valori piccoli di C restringono il margine e riducono il bias al costo di una maggiore varianza. Solo le osservazioni sul margine o che lo violano — i vettori di supporto — influenzano la determinazione dell'iperpiano.

2.3.4 Confini di separazione non lineari e Kernel

Quando nessun iperpiano lineare è in grado di separare le classi, una soluzione consiste nell'ampliare lo spazio delle covariate attraverso trasformazioni polinomiali o, più in generale, attraverso l'uso di **funzioni kernel**. L'idea chiave è che il classificatore lineare con vettori di supporto può essere espresso tramite prodotti scalari tra le osservazioni; sostituendo il prodotto scalare con un kernel $K(x_j, x_k)$, si ottiene implicitamente una proiezione in uno spazio ad alta dimensionalità senza calcolarne esplicitamente le coordinate. Il documento presenta due kernel principali:

- **Kernel polinomiale:**

$$K(x_j, x_k) = (1 + \sum_{i=1}^p x_{ij}x_{ik})^d$$
- **Kernel radiale (RBF):**

$$K(x_j, x_k) = \exp(-\gamma \sum_{i=1}^p (x_{ij} - x_{ik})^2)$$

Quando il classificatore con vettori di supporto è abbinato a un kernel non lineare, si ottiene il

Support Vector Machine in senso stretto.

2.3.5 Aspetti finali

In sintesi, il documento affronta tre questioni conclusive. Per la classificazione **multiclasse**, si propongono le strategie OVA (*One versus All*) e OVO (*One versus One*), con preferenza per quest'ultima quando il numero di classi non è elevato. Sul piano della connessione con altri metodi, si mostra che il classificatore SVM equivale a minimizzare una funzione **perdita + penalità** in cui la perdita è la *hinge loss*, analoga alla log-verosimiglianza negativa della regressione logistica. Infine, si fornisce un orientamento applicativo: SVM è preferibile alla regressione logistica in presenza di classi quasi perfettamente separabili, mentre in caso contrario i due approcci producono risultati comparabili. In R, l'implementazione principale è disponibile tramite la funzione 'svm()' del pacchetto 'e1071'.

2.4 Ensemble di alberi decisionali

Un singolo albero decisionale, pur essendo un approssimatore universale e dotato di alta interpretabilità, presenta una tendenza all'overfitting quando la profondità aumenta. Gli ensemble methods (metodi assemblativi) affrontano questa limitazione combinando più modelli deboli al fine di produrre un classificatore complessivo con prestazioni superiori a quelle di ciascun componente individuale. Il punto di partenza teorico è il concetto di classificatore debole: un modello $h: X \rightarrow Y$ è considerato debole se esiste $\gamma > 0$ tale che la probabilità di errore soddisfa $Pr[h(x) \neq y] \geq \frac{1}{2} - \gamma$. L'obiettivo del boosting è trasformare una sequenza di tali classificatori in un classificatore forte.

2.4.1 Boosting: AdaBoost

Il boosting è un approccio sequenziale: ogni nuovo modello viene addestrato ponendo maggiore enfasi sugli esempi che i modelli precedenti hanno classificato erroneamente. L'algoritmo AdaBoost opera secondo il seguente schema:

Si inizializzano pesi uniformi $D_i(i) = \frac{1}{m}$ per ciascun esempio. Ad ogni iterazione t , si addestra un classificatore debole h_t sul dataset pesato; si calcola il margine di correttezza $r_t = \sum D_t(i) y^i h_t(x^i)$, e si assegna un peso $\alpha_t = \frac{1}{2} \log(\frac{1+r_t}{1-r_t})$ al modello. I pesi degli esempi vengono aggiornati incrementando quelli degli esempi misclassificati. Il classificatore finale è $H(x) = \text{sgn}(\sum \alpha_t h_t(x))$.

Il teorema di convergenza

garantisce che, se ogni classificatore debole ha errore $\leq \frac{1}{2} - \gamma$, l'errore di training del classificatore combinato decresce esponenzialmente come $\exp(-\gamma^2 \frac{T}{2})$ al crescere del numero di iterazioni T . Concretamente, l'errore sul validation set tende anch'esso a decrescere nelle prime iterazioni, stabilizzandosi successivamente, il che lo distingue favorevolmente dall'overfitting tipico dei singoli alberi profondi. Nel contesto degli alberi, il boosting può essere applicato sia a *decision stump* (ceppi di decisione, alberi di profondità 1) sia ad alberi di profondità arbitraria. Nel primo caso, la combinazione lineare di ceppi è matematicamente equivalente a un singolo albero più profondo; nel secondo caso, il risultato è una foresta costruita sequenzialmente.

2.4.2 Bagging: Random Forest

Il bagging introduce una prospettiva alternativa: invece di addestrare i modelli in modo sequenziale e adattivo, li costruisce in parallelo su versioni ricampionate del dataset originale. Questo supera il problema per cui addestrare T volte lo stesso apprendista sullo stesso dataset produrrebbe modelli identici. L'algoritmo Random Forest procede come segue:

Per $t = 1, \dots, T$: si selezionano m' esempi casualmente con rimpiazzo dal dataset originale (bootstrap sample). Si costruisce un albero di decisione h_t su tali esempi, con la variante che in ogni

nodo la scelta della variabile di split avviene tra un sottoinsieme di k feature scelte casualmente (tipicamente $k = \sqrt{d}$ per input d -dimensionali). La classificazione finale avviene per voto a maggioranza tra $h_1, \dots, h_t$.

La doppia fonte di casualità – nel campionamento degli esempi e nella selezione delle feature – assicura la diversità tra gli alberi, condizione necessaria affinché la combinazione produca un miglioramento effettivo rispetto al singolo modello.

Confronto e considerazioni conclusive

Caratteristica	Boosting	Bagging (RF)
Costruzione	Sequenziale	Parallela
Obiettivo	Ridurre bias	Ridurre varianza
Pesi sugli esempi	Adattivi	Uniformi (bootstrap)
Rischio principale	Sensibilità agli outlier	Nessuno dominante

Table 1: Confronto tra Boosting e Bagging

2.5 Normalizzazione dei dati

2.5.1 Definizione e finalità

La normalizzazione dei dati è un processo di trasformazione che riconduce valori numerici appartenenti a scale differenti a un intervallo comune, senza alterare le relazioni proporzionali tra di essi. L'obiettivo primario è eliminare le distorsioni introdotte dalla differenza di grandezza tra variabili, affinché ciascuna contribuisca in modo equo all'analisi o al modello computazionale.

Questa operazione è necessaria ogni volta che si lavora con algoritmi sensibili alla scala dei dati, quali le reti neurali, il metodo dei *k*-nearest neighbors (k-NN), la regressione logistica con regolarizzazione e le support vector machine (SVM).

2.5.2 Motivazione tecnica

Si consideri un dataset con due variabili: l'età di un individuo (range 0–100) e il reddito annuo (range 10.000–100.000). Se queste variabili vengono fornite direttamente a un algoritmo che calcola distanze euclidee, la variabile reddito — per il semplice fatto di avere valori numericamente più grandi — dominerà il calcolo, rendendo di fatto irrilevante la variabile età. La normalizzazione risolve questo problema portando entrambe le variabili su una scala comparabile.

2.5.3 Tecniche principali

1. Min-Max Scaling (Normalizzazione nell'intervallo [0, 1]) È la tecnica più comune. Per ogni

valore x di una variabile, si applica la formula:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Il risultato è un valore compreso tra 0 e 1, dove 0 corrisponde al minimo osservato e 1 al massimo. Questa tecnica preserva la distribuzione originale dei dati, ma è sensibile agli *outlier*: un valore anomalo altera significativamente $x_{\min}$ o $x_{\max}$, comprimendo tutti gli altri valori in un intervallo ristretto.

2. Standardizzazione (Z-score Normalization) La standardizzazione trasforma i dati in modo che abbiano **media zero** e **deviazione standard unitaria**:

$$x' = \frac{x - \mu}{\sigma}$$

dove μ è la media della variabile e σ la sua deviazione standard. A differenza del Min-Max Scaling, questa tecnica non delimita l'intervallo dei valori trasformati, ma è più robusta rispetto agli *outlier*. È preferibile quando la distribuzione dei dati si approssima a una gaussiana, o quando l'algoritmo impiegato assume che i dati siano centrati attorno allo zero.

3. Robust Scaling Per dataset con *outlier* marcati, il Robust Scaling utilizza la **mediana** e l'**intervallo interquartile (IQR)**:

$$x' = \frac{x - \text{mediana}}{\text{IQR}}$$

Poiché mediana e IQR non sono influenzati dai valori estremi, questa tecnica produce trasformazioni più stabili rispetto alle due precedenti.

4. Normalizzazione L^2 (per vettori) In contesti come il text mining o i sistemi di raccomandazione, si normalizza l'intero vettore di osservazione dividendo ciascun elemento per la norma euclidea del vettore stesso:

$$\mathbf{x}' = \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$$

Il vettore risultante ha norma unitaria e rappresenta quindi la direzione del vettore originale, indipendentemente dalla sua magnitudine.

2.5.4 Quando normalizzare e quando non farlo

Non tutti gli algoritmi richiedono la normalizzazione. Gli alberi decisionali e le foreste casuali (*Random Forest*), ad esempio, operano su soglie di suddivisione e sono invarianti rispetto alla scala delle variabili. Applicare la normalizzazione in questi casi è computazionalmente neutro ma non apporta benefici.

Al contrario, è indispensabile nei seguenti contesti:

2.5.5 Considerazioni pratiche

Un errore metodologico frequente consiste nel calcolare i parametri di normalizzazione (minimo, massimo, media, deviazione standard) sull'intero dataset prima della suddivisione in *training set* e *test set*. Questo introduce il **data leakage**: le informazioni del *test set* influenzano la trasformazione applicata al *training set*, producendo una stima ottimistica delle prestazioni del modello. La procedura corretta prevede di calcolare i parametri esclusivamente sul *training set* e di applicare la stessa trasformazione — con quegli stessi parametri — al *test set*.

2.5.6 Conclusione

La normalizzazione è un passaggio preliminare fondamentale nel preprocessing dei dati. La scelta della tecnica appropriata dipende dalla natura della distribuzione dei dati, dalla presenza di *outlier* e dall'algoritmo che verrà impiegato. Una normalizzazione corretta migliora la stabilità numerica dell'addestramento, accelera la convergenza e garantisce che il confronto tra variabili avvenga su basi metricamente coerenti.

Algoritmo	Necessità di normalizzazione
Reti neurali	Alta
k -NN	Alta
SVM (kernel RBF)	Alta
Regressione lineare/logistica (regolarizzata)	Alta
PCA	Alta (varianze comparabili)
Alberi decisionali / Random Forest	Non necessaria
Naive Bayes	Non necessaria

Table 2: Necessità di normalizzazione per i principali algoritmi di machine learning.

3 Possibili implementazioni

In precedenza (vedi cap 1.2) è già stato menzionato qualche esempio di implementazione di tali algoritmi, e di come, molto spesso, possano giovare alla vita dell'uomo. Di seguito elencheremo i vari ambiti che potrebbero, che possono, che sono e che saranno potenziati grazie all'uso dell'hand tracking. È importante, inoltre, evidenziarne gli aspetti economici, gli approcci tecnici attuati e l'impatto sociale che avrebbe una simil implementazione, considerandone benefici e sfide, e avvalendosi di qualche caso reale per sostenere ciò che segue.

3.1 Realtà virtuale e aumentata

Nei sistemi immersivi VR e AR, il tracciamento delle mani permette interazioni naturali con l'ambiente digitale — tendenzialmente oggetti virtuali — mediante il riconoscimento di gesti (*gesture*) eseguiti con gli arti superiori. Gli ultimi visori, di nuova generazione, ad esempio Meta Quest, HoloLens 2 e Apple Vision Pro, mediante l'uso di telecamere integrate e modelli IA, sono in grado di ricostruire in tempo reale la postura di mani e dita affinché tali gesti possano essere tradotti in input per l'azione che si desidera eseguire. Ad esempio, [HoloLens 2](#) di Microsoft sfrutta il sensore di profondità *time-of-flight* combinato con modelli di intelligenza artificiale integrata per tracciare lo scheletro della mano; [analogamente](#), i visori [Meta Quest](#) (di Meta, ovviamente) usano telecamere frontali per seguire i movimenti delle mani e, successivamente, visualizzarle in realtà virtuale come *silhouette*. Per quanto riguarda [Apple Vision Pro](#), il tracciamento a 90Hz migliora la reattività nei giochi spaziali, riducendo latenza, eliminando il *motion blur* (sfocatura da movimento) e prevenendo la cinetosi (nausea da movimento).

Per sottolineare maggiormente la prestanza di questi visori è bene esemplificarne qualcuno: i caschi di Meta Quest supportano il tracciamento senza controller, permettendo, come prima detto, di afferrare e toccare menu con le dita per grazia di una funzione chiamata [Direct Touch](#); similmente, HoloLens 2 permette di toccare e muovere ologrammi con le mani. Fondamentalmente, l'approccio tecnico adottato è basato su una visione computerizzata: telecamere stereo RGB e IR (altri sensori di profondità) catturano immagini delle mani. Gli algoritmi di machine learning (sostanzialmente, reti neurali) si occupano di stimare le posizioni delle articolazioni riconoscendo gesti specifici. Molti sistemi usano modelli scheletrici con *landmark*, che non sono altro che dei marcatori sulle giunture (falangi, polso, punta delle dita ecc.) che permettono di ricostruire il gesto della mano, per calcolare pose 3D. In alcuni casi, tendenzialmente nei prototipi di ricerca, si sperimentano sensori aggiuntivi indossabili elettromiografi (sensori per i muscoli) per aumentare la precisione e la robustezza. È, dunque, evidente che i principali usi dell'hand tracking spazino dal gaming immersivo al training simulato e, profes-

sionalmente, dalla progettazione collaborativa in realtà aumentata alla formazione professionale.

Quest'approccio innovativo ha portato con sé un'immersione più alta e interazioni più intuitive rispetto a quelle che si potrebbero avere con un controller fisico, migliorando comfort e accessibilità: vedere le proprie mani in virtuale aumenta la **presenza** e il realismo. Inoltre, nell'addestramento, che sia sanitario o militare, sono consentiti esercizi più efficaci e spontanei. Occorre dire che questa tecnologia è spesso presentata, integrata, come opzione e non come sostituto completo dei controller: il tracking deve essere a bassa latenza (<20-50 ms) per evitare disorientamento ed errore percepito. Occlusioni (mano coperta) e condizioni di luce critiche possono alterare la precisione. Tuttavia, è certo che la tecnologia è matura per il mercato consumer e che ha ampio margine di miglioramento.

3.2 Automobilistica

Nel settore auto il tracciamento viene impiegato principalmente per il controllo a mani libere (*hand-free*) dell'*infotainment* (informazioni e intrattenimento), aumentando la sicurezza e riducendo la distrazione. Per esempio, *alcuni gesti* come puntare con l'indice o compiere azioni di "scorrimiento" permettono di alzare o abbassare il volume, rispondere a chiamate o di interagire con il navigatore, senza che nulla venga concretamente toccato. Resta comunque possibile integrare touchscreen e comandi vocali affinché il conducente non distolga lo sguardo dalla strada.

BMW, con *BMW Gesture Control*, ha introdotto nel 2015 sulla Serie 7 un sensore 3D posizionato sopra la console centrale per rilevare *movimenti semplici*: puntare il dito verso lo schermo per accettare una chiamata; ruotare indice e pollice per operare sul volume; aprire e chiudere la mano per aprire funzioni configurabili e via scorrendo. In alcuni modelli Mercedes, *Mercedes MBUX Interieur Assist* riconosce il movimento della mano per azionare luci interne o rispondere a chiamate. La tecnologia è applicata principalmente a vetture di fascia alta ma si sta espandendo anche verso la fascia media grazie a soluzioni a minor costo.

Per consentire l'interazione con l'automobile si fa uso, tipicamente, di sensori di profondità (come HoloLens 2) oppure di telecamere IR 3D con illuminatori posti vicino allo specchietto retrovisore. I dati grezzi vengono poi processati da chip MCU (MicroController Unit) o DSP (Digital Signal Processor) e successivamente passati ad algoritmi di riconoscimento di gesti. *Analog Devices* ha proposto un approccio integrato con array fotodiodi (sensori costituiti da recettori che convertono la luce in impulsi elettrici), riducendo costi e complessità rispetto alle telecamere ToF tradizionali. Alcuni sistemi offrono il riconoscimento di mani e volto e anche degli occhi per aumentare il contesto.

Nel concreto delle cose, fornire alle autovetture nuovi sistemi che permettano un nuovo tipo di interazione più diretta aumenterebbe di gran lunga la sicurezza stradale grazie alla riduzione delle distrazioni, oltre che

alla comodità d'uso e all'accessibilità, permettendo anche a persone sorde o mute di poter mettersi alla guida con minore difficoltà. Il controllo di gesti non richiede contatto fisico, quindi non si usurano componenti sensibili e, in aggiunta, integrare input multimodali (gesto + voce) migliora l'esperienza dell'utente.

L'alta complessità hardware-software ha finora limitato l'adozione alle auto di lusso, per via di costi elevati e necessità di taratura. Gli algoritmi devono essere robusti a varie condizioni di illuminazione nell'abitacolo e non confondere i gesti involontari con comandi, accentuando il problema di falsi positivi. Ci sono vincoli di latenza: il sistema deve reagire in tempo reale (idealmente $<100\text{ms}$) per essere percepito naturale dal guidatore. Va inoltre considerata la sicurezza funzionale nel caso di comandi critici. La maturità è media: diverse case, tra le quali BMW, Audi e Mercedes, offrono funzioni gestuali su modelli di alta gamma, ma la tecnologia è ancora in evoluzione per la fascia di massa.

3.3 Robotica e automazione industriale

Nel campo industriale e robotico il tracciamento delle mani abilita il controllo a mani libere di macchine e robot, migliorandone sicurezza e efficienza. Ad esempio, un operatore può impartire comandi gestuali a un braccio robotico remoto o arrestare immediatamente un macchinario in caso di emergenza riconoscendo la sua mano nelle vicinanze. Viene inoltre usato in simulatori di formazione e in telemanipolazione e teleoperazione. Nei robot collaborativi (i *cobot*), la visione artificiale monitora costantemente lo spazio di lavoro e riconosce la presenza delle mani umane per modulare la velocità o fermare il robot.

Con *MediaPipe*, come descritto da ElectronicsForYou, è possibile pilotare un braccio robotico in tempo reale usando una semplice webcam e il modello [MediaPipe](#) per il rilevamento delle mani. Il browser estrae i landmarks della mano e successivamente invia le coordinate a un microcontrollore (tipicamente Arduino) che aziona i motori. Questo approccio senza hardware aggiuntivo è utile in ambienti industriali dove si preferisce evitare contatti con macchinari potenzialmente pericolosi. Altri esempi includono sistemi di realtà aumentata per operazioni di manutenzione dove il tecnico usa le mani per manipolare istruzioni virtuali.

L'approccio utilizzato è prevalentemente basato su camere industriali ad alta risoluzione RGB o stereo con illuminazione controllata e algoritmi di machine learning per il riconoscimento gesti. Vengono utilizzate librerie Google MediaPipe o modelli personalizzati per estrarre in tempo reale le coordinate in tre dimensioni di dita e palmo. Alcuni sistemi adottano guanti con segmenti elettromiografici per aumentare la precisione nei casi di movimento veloce o occlusioni. In ogni caso, il tracciamento deve essere altamente affidabile e con bassa latenza (tipicamente $<100\text{ms}$) per poter integrare i segnali di arresto di emergenza o comandi rapidi. I sistemi di sicurezza industriale integrano anche algoritmi di visione per

riconoscimento posizionale.

La sicurezza avanzata e delle interfacce più naturali aumentano sensibilmente il benessere dei lavoratori. Automatizzare la supervisione della sicurezza sfruttando l'[hand tracking](#) per arrestare robot, riduce gli infortuni legati all'errore umano. Il controllo robotico basato su gesti può aumentare la produttività e migliorare la flessibilità nelle linee di produzione. Non ultimo, in contesti sanitari, come nella chirurgia robotica, permette al chirurgo di manipolare braccia robotiche con le mani con interfacce basate su guanti o sensori, sebbene spesso si privilegi il tocco diretto su controlli dedicati. Le occlusioni frequenti, la variabilità nell'illuminazione industriale e rumore possono interferire con la visione. La sicurezza funzionale deve essere certificata e i sistemi devono essere robusti a malfunzionamenti del software di visione. Inoltre, il networking in tempo reale deve garantire latenza minima.

La tecnologia è in rapida adozione: start-up come *ManoMotion* spingono per una sicurezza touchless sfruttando semplici videocamere e IA, ma spesso restano progetti pilota. In generale, il livello di maturità va da sperimentale a disponibile in nicchie industriali avanzate, ma non è ancora ubiquo.

3.4 Marketing immersivo

Nei negozi al dettaglio e nelle attività promozionali il tracciamento delle mani crea esperienze d'acquisto coinvolgenti e senza contatto (*contactless*). Esempi tipici includono specchi smart che mostrano prodotti AR sui clienti e chioschi interattivi dove il passante controlla contenuti e cataloghi con il gesto. Durante eventi o *in-store activation*, i visitatori possono giocare con presentazioni interattive usando il proprio corpo come controller.

Nike, con [Nike AR Mirror](#), nel 2025 ha installato uno specchio intelligente che, tramite tecnologia AR di Snapchat, consentiva ai clienti di provare virtualmente cappellini e occhiali. Gli utenti facevano gesti semplici come trascinare la mano per scorrere tra gli articoli e provare i prodotti in sovraimpressione. Questa esperienza, oltre a intrattenere, aumentava la permanenza in negozio e le condivisioni social creando passaparola. Di solito si utilizza una telecamera RGB integrata nello specchio o nel chiosco, abbinata ad un software AR che sovrappone immagini digitali sul video in tempo reale. Sistemi come quelli di Snapchat ARES permettono il posizionamento accurato di oggetti 3D sulle mani e sul corpo del cliente. Anche sensoristica a infrarossi può essere impiegata per migliorare il rilevamento in ambienti con scarsa illuminazione. La piattaforma chiave è il software di computer vision che riconosce la silhouette della persona e i movimenti delle mani, attivando animazioni o cambi di scena al volo.

Grazie a questa trovata i clienti si sentono protagonisti di un'esperienza interattiva, aumentando fidelizzazione e acquisti. Touchless è particolar-

mente attrattivo in epoca post-pandemia. È un potente strumento di marketing: i contenuti generati dagli utenti (es. selfie AR condivisi) amplificano la visibilità del brand. Inoltre, consente al personale di spiegare prodotti senza contatto fisico, utile per l'igiene e l'accessibilità. Il sistema dev'essere, però, intuitivo e riconoscere gesti naturali, oltre che essere robusto a più utenti contemporanei: potrebbero servire telecamere multiple per diverse angolazioni. Le occlusioni possono mandare il tracking in crisi. Serve notevole potenza di calcolo per AR in tempo reale di alta qualità. Infine, il costo d'installazione può essere alto, limitando, per ora, l'utilizzo alle grandi catene o eventi di lusso. In termini normativi, non ci sono particolari vincoli aggiuntivi, ma in Europa bisogna sempre rispettare la privacy nel trattamento delle immagini video dei clienti (GDPR) quando queste vengono immagazzinate o analizzate.

Molte case di moda come Nike, IKEA virtual mirror stanno sperimentando queste soluzioni, ma rimane un trend in forte crescita piuttosto che uno standard di massa.

3.5 Sanità e accessibilità

Nelle applicazioni sanitarie e di assistenza il tracciamento delle mani può supportare la riabilitazione motoria, la chirurgia robotica e la comunicazione per persone con disabilità uditive o motorie. In ambito terapia fisica si studiano sistemi di realtà virtuale che registrano la qualità dei movimenti di recupero impiegando visione 3D o sensori indossabili. Per l'assistenza ai non udenti, il tracciamento di gesti è alla base di strumenti di traduzione in lingua dei segni.

Accessible Translation, finanziata dall'UE, ha realizzato un'app che acquisisce via fotocamera i gesti in LIS (Lingua Italiana Segni) e li converte automaticamente in testo o parlato. L'IA riconosce i segni grazie a modelli ML addestrati su dataset di gestualità, offrendo comunicazione in tempo reale anche senza hardware specializzato come guanti sensorizzati. Soluzioni simili, ad esempio Google Hand Talk, usano video in ingresso e reti neurali per interpretare gesti comuni e frasi. Videocamere standard rilevano i movimenti delle mani e algoritmi di intelligenza artificiale (*deep learning*) interpretano pose e gesti. Nella chirurgia robotica avanzata, talvolta si adottano guanti sensorizzati per aumentare l'affidabilità, ma si stanno esplorando anche interfacce a infrasuoni per tracciare le mani senza contatto nell'area sterile. In riabilitazione, si combinano spesso tracker ottici con interfacce VR immersive per migliorare la motivazione del paziente. In contesti di assistenza, la privacy è cruciale: di solito il riconoscimento avviene localmente sul dispositivo per non trasmettere immagini di pazienti o utenti sensibili.

Lo sviluppo di tecnologie basate sull'hand tracking in questo ambito promuove l'inclusività aiutando sordi e non vedenti a comunicare, grazie alla traduzione da parlato a segni e viceversa. In terapia motoria, invece, può fornire feedback quantitativo in tempo reale, aumentando

l'efficacia del recupero. In sala operatoria consente al chirurgo di mantenere sterile il campo cambiando viste o isolando strumenti robotici con gesti riconosciuti. In generale, riduce la necessità di dispositivi fisici, utile per l'igiene, per diminuzione di contatto. Il livello di precisione richiesto resta molto alto: piccoli errori possono avere conseguenze gravi. In ambito medico e assistenziale si applicano norme severe come il *Medical Device Regulation UE*, perciò ogni sistema va certificato e validato clinicamente. Gli algoritmi devono gestire incertezza semantica perché un gesto di segno può avere significato diverso da un gesto di comando. C'è inoltre il rischio di falsi positivi o negativi che, ad esempio, in terapia possono demotivare l'utente. La latenza deve essere minima (<100ms) per percepire un feedback naturale.

In ambito sanitario il tracciamento delle mani è ancora in fase di ricerca e sperimentazione clinica, mentre per applicazioni assistive le soluzioni commerciali sono poche e spesso poco affidabili. Tuttavia, la crescente disponibilità di modelli machine-learning pre-addestrati e sensori economici rende il settore pronto per innovazioni future.

Settore	Sensori tipici	Latenza	Precisione	Sicurezza / Normative	Maturità
VR/AR e gaming	Telecamere RGB/IR, depth sensor	Molto bassa (<20-50 ms)	Molto alta (mm, singolo dito)	Richieste ergonomiche minori	Elevata
Automotive	Sensori ToF/3D, camere IR	Bassa (<100 ms)	Media (cm)	ISO 26262	Media-alta
Consumer electronics	Fotocamera RGB	Moderata (50-100 ms)	Media (gesti generali)	Privacy GDPR	Elevata
Robotica / Industria	Camere RGB/IR, guanti IMU	Molto bassa (<50-100 ms)	Alta	ISO TS 15066, IEC 60204	In sviluppo
Retail / Marketing	Telecamere RGB/3D	Moderata (<100 ms)	Media	GDPR, normative eventi	Emergente
Sanità / Accessibilità	Fotocamere RGB, sensori IMU	Molto bassa (<50-100 ms)	Molto alta	Regolamentazione MDR	Sperimentale

Table 3: Confronto tra i principali settori applicativi dell'hand tracking

4 La nostra visione

Il nostro progetto di hand tracking rappresenta una base tecnologica estremamente versatile che consente di esplorare molteplici direzioni applicative in ambiti differenti. Partendo dalla capacità intrinseca di riconoscere e tracciare i movimenti delle mani in tempo reale, è possibile sviluppare soluzioni che spaziano dall'interazione uomo-macchina avanzata fino a contesti di monitoraggio biomedico e analisi comportamentale.

4.1 Alternativa a mouse e tastiera

Una prima direzione implementativa riguarda lo sviluppo di interfacce gesture-based per applicazioni desktop e mobile. Attraverso il riconoscimento di gesti specifici delle mani, è possibile creare sistemi di controllo alternativi ai tradizionali input da tastiera e mouse. Questo approccio risulta particolarmente rilevante in contesti dove l'interazione tattile risulta problematica o inefficiente, come ad esempio in ambienti medici sterili, situazioni di mobilità ridotta o durante l'uso di dispositivi indossabili. L'implementazione di un sistema di questo tipo richiederebbe la definizione di una libreria di gesti standardizzati, la costruzione di modelli di machine learning capaci di discriminare tali gesti con precisione superiore al novantacinque per cento, e l'integrazione con framework di interfaccia utente già consolidati come Qt o Electron per garantire una compatibilità trasversale.

4.2 Realtà Virtuale e Aumentata

Una seconda possibilità implementativa riguarda l'ambito della realtà virtuale aumentata, dove il hand tracking assume un ruolo centrale nella creazione di esperienze immersive convincenti. Molte piattaforme commerciali come Meta Quest e stanno investendo massicciamente in questa direzione, riconoscendo che la capacità di tracciare le mani degli utenti direttamente nell'ambiente virtuale elimina la necessità di dispositivi di controllo esterni e aumenta significativamente il senso di immersione. Nel contesto di questo progetto, una possibile implementazione consisterebbe nello sviluppo di un modulo di rendering tridimensionale che rappresenti le mani dell'utente nello spazio virtuale con latenza inferiore ai venti millisecondi, garantendo una sincronizzazione percettiva adeguata tra i movimenti reali e la loro rappresentazione virtuale. Tale modulo potrebbe integrarsi con motori grafici diffusi come Unreal Engine o Unity, sfruttando le loro pipeline di rendering ottimizzate e i loro sistemi di gestione delle particelle per creare feedback visivi convincenti.

4.3 Comunicazione inclusiva

Un terzo ambito di sviluppo riguarda l'applicazione del hand tracking nel contesto della comunicazione gestuale e dell'accessibilità. Esiste una crescente consapevolezza circa l'importanza di sviluppare tecnologie che facilitino l'inclusione di persone sorde e ipoudenti, e il riconoscimento automatico del linguaggio dei segni rappresenta una frontiera tecnologica di grande rilevanza sociale. Un'implementazione in questa direzione comporterebbe la raccolta di dataset estesi di gesti del linguaggio dei segni in collaborazione con comunità sorde, l'adattamento di architetture di deep learning come le reti ricorrenti e i transformer per gestire sequenze temporali di pose manuali, e infine lo sviluppo di sistemi di traduzione in tempo reale che convertano sequenze di segni in testo o voce sintetizzata. Progetti come quello della ASL Recognition di Google e i research di DeafTech dimostrano la viabilità di questo approccio, sebbene rimangano significative sfide tecniche legate alla variabilità dei gesti, agli angoli di visione diversi e alle differenze dialettali nei diversi linguaggi gestuali.

4.4 Monitoraggio atletico

Un quarto ambito potrebbe riguardare l'implementazione di sistemi di analisi biomeccanica e monitoraggio del gesto atletico. Nel contesto dello sport e della riabilitazione fisica, la capacità di tracciare con precisione millimetrica i movimenti delle mani consente di fornire feedback dettagliati agli atleti e ai pazienti circa la correttezza della loro esecuzione motoria. Sistemi come quello sviluppato da Kinema Technologies e le soluzioni di motion capture ottico rappresentano riferimenti consolidati in questo ambito, ma il costo proibitivo di tali sistemi crea un'opportunità per soluzioni basate su visione artificiale più accessibili. Un'implementazione di questo tipo richiederebbe l'integrazione di modelli biomeccanici articolati, la validazione dei dati tracciati rispetto a sistemi di riferimento a infrarossi, e lo sviluppo di algoritmi di analisi che estrarrebbero parametri significativi come velocità angolari, accelerazioni lineari e momenti articolari per fornire feedback correttivo agli utenti.

4.5 Addestramento medico

Una quinta direzione riguarda lo sviluppo di applicazioni di e-learning interattivo e simulazione medica. Nel contesto della formazione chirurgica, ad esempio, la simulazione di interventi con feedback tattile e visivo rappresenta un elemento cruciale per lo sviluppo delle competenze. Integrando il hand tracking con dispositivi haptic e modelli anatomici tridimensionali dettagliati, è possibile creare ambienti di training immersivi dove gli studenti possono praticare procedure chirurgiche complesse prima di operare su pazienti reali. Organizzazioni come il National Board of Medical Examiners e vari dipartimenti universitari stanno esplorando questo tipo

di soluzioni per incrementare l'efficacia della formazione e ridurre i rischi associati all'apprendimento sul paziente reale.

4.6 Monitoraggio psico-fisico

Un sesto ambito implementativo riguarda l'analisi comportamentale e la psicologia cognitiva. Il gesto manuale comunica informazioni ricche circa lo stato emotivo, il livello di ansia, la concentrazione e i processi cognitivi sottostanti. Ricerche condotte presso l'Università di Stanford e il MIT dimostrano che l'analisi quantitativa dei gesti può fornire indicatori affidabili di diverse condizioni psicologiche. Un sistema sviluppato su questa base potrebbe essere applicato nel contesto della telemedicina psichiatrica, nell'assessment dell'autismo, o nell'identificazione precoce di disturbi neurodegenerativi come il Parkinson. L'implementazione comporterebbe l'estrazione di feature geometriche e temporali dalle traiettorie manuali, l'addestramento di modelli classificatori multiclasse, e lo sviluppo di interfacce che consentano ai clinici di interpretare le analisi quantitative nel contesto della valutazione clinica tradizionale.

4.7 Robotica

Un settimo ambito potrebbe riguardare lo sviluppo di sistemi di controllo per dispositivi robotici. Particolarmente interessante è la possibilità di implementare sistemi di teleoperazione dove un operatore umano controlla un robot remoto attraverso la replicazione dei propri movimenti manuali. Questo approccio trova applicazioni cruciali in contesti ad alto rischio come la difesa nucleare, l'esplorazione spaziale, e le operazioni di disattivazione di ordigni esplosivi. L'implementazione richiederebbe lo sviluppo di un sistema di mapping tra lo spazio delle pose manuali umane e lo spazio delle configurazioni articolari del robot, la gestione della latenza di comunicazione attraverso algoritmi di predizione, e l'implementazione di sistemi di sicurezza che impediscano movimenti pericolosi da parte del robot anche in caso di disconnessione comunicativa.

4.8 Pagamenti fluidi

Un ottavo ambito riguarda l'implementazione di sistemi di pagamento e autenticazione biometrica basati sul riconoscimento della geometria manuale. Sebbene il riconoscimento facciale sia attualmente il metodo biometrico più diffuso, il riconoscimento della geometria manuale presenta vantaggi significativi in termini di stabilità nel tempo e resistenza al falsamento. Un sistema di questo tipo potrebbe essere implementato in contesti di sicurezza fisica, accesso a strutture critiche, o autenticazione nei sistemi bancari. L'implementazione comporterebbe la raccolta e gestione di database biometrici conformi alle normative sulla privacy come

il GDPR, lo sviluppo di algoritmi di enrollment e matching con tassi di falsi positivi inferiori all'uno per milione, e l'integrazione con sistemi di gestione identità già consolidati.

4.9 Benessere sonoro (musica)

Un nono ambito potrebbe riguardare lo sviluppo di applicazioni musicali interattive dove il hand tracking abilita forme innovative di interazione musicale. Musicisti e composer potrebbero utilizzare i movimenti delle mani nello spazio per controllare parametri sintetici, effetti audio, o per interfacciarsi con strumenti virtuali in modo più espressivo rispetto alle attuali interfacce MIDI. Progetti sperimentali presso istituti come il MIT Media Lab dimostrano il potenziale artistico di tali approcci. L'implementazione richiederebbe la definizione di schemi di mapping intuitivi tra lo spazio gestuale e lo spazio dei parametri audio, l'integrazione con digital audio workstation popolari, e la gestione della latenza audio sub-centesimale.

4.10 Supervisione della salute

Infine, un decimo ambito potrebbe riguardare lo sviluppo di sistemi di monitoraggio della salute occupazionale per la prevenzione di lesioni da movimento ripetitivo. In ambienti industriali e di ufficio, il tracking continuativo dei movimenti manuali potrebbe identificare pattern biomeccanici scorretti che aumentano il rischio di patologie come la sindrome del tunnel carpale. Un sistema di questo tipo potrebbe fornire feedback in tempo reale ai lavoratori, allertarli quando adottano posture a rischio, e generare rapporti aggregate per i datori di lavoro circa i rischi ergonomici presenti nell'ambiente di lavoro. L'OSHA e organizzazioni simili in altri paesi stanno promuovendo approcci tecnologici di questo tipo per incrementare gli standard di sicurezza occupazionale.

4.11 Conclusioni

La molteplicità delle implementazioni possibili descrive il profondo potenziale trasformativo che la tecnologia di hand tracking è destinata a catalizzare. Questa tecnologia rappresenta il prossimo salto evolutivo nell'interazione uomo-macchina, eliminando la necessità di strumenti intermediari e consentendo un dialogo naturale paragonabile alla comunicazione umana istintiva.

Nel contesto dell'accessibilità, l'hand tracking offre la possibilità di creare tecnologie genuinamente inclusive, dove persone con caratteristiche fisiche diverse possono interagire con la stessa interfaccia digitale in modo naturale e immediato. Nel settore sanitario, consente il monitoraggio continuo e non invasivo dello stato di salute, potendo identificare

con anticipo segni precoci di malattie neurodegenerative e disturbi psichiatrici. In ambito educativo, democratizza l'accesso a forme di training sofisticato precedentemente riservate a pochi privilegiati, consentendo a un chirurgo in formazione in qualsiasi parte del mondo di praticare procedure complesse attraverso ambienti di simulazione avanzati.

Tuttavia, realizzare questo potenziale richiede non solo eccellenza tecnica, ma una riflessione profonda su etica, privacy e giustizia sociale. Il tracciamento dei movimenti manuali rappresenta una raccolta dati corporei estremamente sensibile e la responsabilità di gestire tale informazione con appropriata cautela è cruciale. Il rischio di consolidare ulteriormente le disparità economiche globali richiede una consapevolezza critica costante e la promozione di approcci open-source e decentralizzati.

In conclusione, questo progetto si colloca in una posizione temporale particolarmente significativa, rappresentando un punto di innesco potenziale per una trasformazione profonda di come gli esseri umani interagiscono con la tecnologia. Le implementazioni discusse testimoniano un paesaggio applicativo vasto e in evoluzione. Il valore reale risiede nella creazione di una piattaforma fondazionale robusta su cui ecosistemi di innovazione possono essere costruiti, perseguendo consapevolmente una direzione di sviluppo realmente trasformativa e inclusiva.

References

- [1] Krueger, M. W. (1969). *Glowflow: An Interactive Installation*. University of Wisconsin.
- [2] Krueger, M. W. (1974). *Videoplace and Responsive Environments*. University of Wisconsin.
- [3] Krueger, M. W. (1983). *Artificial Reality*. Addison-Wesley.
- [4] Turner, J. (2002, January 23). *Interview on Artificial Reality*. Retrieved from personal archives.
- [5] Lanier, J., & VPL Research. (1987). *DataGlove: The First Commercial Virtual Reality Glove*. VPL Research, Inc.
- [6] Microsoft. (2010). *Kinect: Full Body Sensor for Xbox 360*. Retrieved from <https://www.microsoft.com/en-us/kinect/>
- [7] MarketsAndMarkets. (2025). *Wearable Electronics Market Report*. Retrieved from <https://www.marketsandmarkets.com/>
- [8] Meta Platforms, Inc. *Meta Quest Hand Tracking Technology*. Retrieved from <https://www.meta.com/quest/>
- [9] HTC. *HTC Vive Hand Tracking*. Retrieved from <https://www.vive.com/>
- [10] Apple, Inc. *Apple Vision Pro - Hand Tracking at 90Hz*. Retrieved from <https://www.apple.com/apple-vision-pro/>
- [11] Microsoft. (2023). *HoloLens 2 Hand Tracking and Gesture Recognition*. Retrieved from <https://www.microsoft.com/en-us/hololens/>
- [12] BMW Group. (2015). *BMW Gesture Control - Series 7*. Retrieved from <https://www.bmwusa.com/>
- [13] Mercedes-Benz. *Mercedes MBUX Interieur Assist - Hand Gesture Recognition*. Retrieved from <https://www.mercedes-benz.com/>
- [14] Analog Devices, Inc. *3D Time-of-Flight Technology for Automotive Applications*. Retrieved from <https://www.analog.com/>
- [15] Snapchat, Inc. *Snapchat ARES - Augmented Reality Engine*. Retrieved from <https://www.snapchat.com/>
- [16] Nike, Inc. (2025). *Nike AR Mirror - In-Store Experience*. Retrieved from <https://www.nike.com/>
- [17] IKEA. *IKEA Virtual Mirror and AR Solutions*. Retrieved from <https://www.ikea.com/>
- [18] Accessible Translation Project. *App for LIS (Italian Sign Language) Recognition and Translation*. European Union-funded project.
- [19] Google. *Google Hand Talk - Sign Language Translation Technology*. Retrieved from <https://www.google.com/>
- [20] Google Research. *ASL Recognition - American Sign Language Project*. Retrieved from <https://research.google.com/>

- [21] DeafTech. *Research on Deaf Technology and Sign Language Recognition*. Retrieved from <https://deaftech.org/>
- [22] Kinema Technologies. *Motion Capture and Biomechanical Analysis Systems*. Retrieved from <https://kinema.com/>
- [23] National Board of Medical Examiners. *Medical Education and Simulation Technologies*. Retrieved from <https://www.nbme.org/>
- [24] Stanford University. (2023). *Gesture Analysis and Cognitive Psychology Research*. Department of Psychology.
- [25] MIT Media Lab. *Hand Tracking Applications in Music and Interactive Art*. Retrieved from <https://www.media.mit.edu/>
- [26] Massachusetts Institute of Technology. *Gesture Recognition and Psychological Assessment Research*. MIT Department of Brain and Cognitive Sciences.
- [27] Occupational Safety and Health Administration. *Guidelines on Occupational Health and Ergonomic Monitoring*. Retrieved from <https://www.osha.gov/>
- [28] International Organization for Standardization. (2021). *ISO 26262: Functional Safety of Road Vehicles*. Geneva: ISO.
- [29] International Organization for Standardization. (2016). *ISO/TS 15066: Collaborative Robots - Safety*. Geneva: ISO.
- [30] International Electrotechnical Commission. (2016). *IEC 60204-1: Safety of Machinery - Electrical Equipment*. Geneva: IEC.
- [31] European Union. (2018). *General Data Protection Regulation (GDPR)*. Retrieved from <https://gdpr-info.eu/>
- [32] European Commission. (2017). *Medical Device Regulation (MDR) 2017/745*. Official Journal of the European Union.
- [33] ElectronicsForYou. *MediaPipe Hand Tracking for Robotic Control*. Retrieved from <https://www.electronicsforu.com/>
- [34] Google. *MediaPipe - Hand Detection and Tracking Framework*. Retrieved from <https://mediapipe.dev/>
- [35] ManoMotion. *Gesture Recognition and Touchless Control Solutions*. Retrieved from <https://www.manomotion.com/>
- [36] Unity Technologies. *Unity Game Engine - Real-time 3D Development Platform*. Retrieved from <https://unity.com/>
- [37] Epic Games. *Unreal Engine - 3D Graphics and Game Development*. Retrieved from <https://www.unrealengine.com/>
- [38] The Qt Company. *Qt Framework - Cross-platform Application Development*. Retrieved from <https://www.qt.io/>
- [39] OpenJS Foundation. *Electron - Build Cross-platform Desktop Applications*. Retrieved from <https://www.electronjs.org/>

- [40] Costantino, M. (2019). *Object Detection e Regressione*. Università degli Studi di Padova. Retrieved from https://thesis.unipd.it/retrieve/e0d960b8-1a63-4399-9de3-1dbc77f49812/Costantino_Marco.pdf
- [41] Giapi, G. (2019). *Stima Bayesiana Ricorsiva*. Dipartimento di Ingegneria dell'Informazione, Università degli Studi di Padova. Retrieved from <https://www.dei.unipd.it/giapi/BayesStimaFiltraggio1.pdf>
- [42] Basili, R. (2013). *Classificazione a Massimo Margine: Support Vector Machines*. Università di Roma Tor Vergata. Retrieved from https://art.uniroma2.it/basili/didattica/WmIR/svms_aa_13_14.pdf
- [43] Bonifaci, V. (2011). *Ensemble di Alberi Decisionali*. Dipartimento di Matematica, Università di Roma Tre. Retrieved from https://ricerca.mat.uniroma3.it/users/vbonifaci/in550/070-alberi_notes2.pdf
- [44] Università degli Studi di Verona. (2015). *Normalizzazione dei Dati*. Dipartimento di Informatica. Retrieved from <https://www.di.univr.it/documenti/OccorrenzaIns/matdid/matdid991452.pdf>